论文阅读 When Agent Go Rogue

一、论文介绍

这是一篇 **ICML 2026 会议论文**，收录于 *Proceedings of Machine Learning Research*（PMLR）第 306 卷，论文页码 141833–141852。

《当智能体“失控”：基于激活状态的多智能体恶意行为检测》

作者提出 **AcMAS**，核心思路是：不要只检查 Agent 说出来的话，或依赖完整的 Agent 通信图来追踪恶意行为；还可以观察各个 Agent 模型内部的激活状态，从中识别恶意行为信号，并据此检测、辅助恢复受影响的 Agent。

它针对的问题是：多 Agent 系统中的恶意行为可能被自然语言包装得很隐蔽；同时，Agent 往往异步运行，消息和行为并不严格同步。这使得依赖显式恶意文本特征或同步交互图的方法容易失效。论文主张，分析各 Agent 本地的内部激活信息，能在不依赖显式交互图的情况下，更稳健地检测恶意行为，并为恢复 Agent 功能提供线索。

二、论文方法、实验与结果

1. 现有防护的两个难点

作者指出，许多已有的多 Agent 防御方法依赖两个假设：一是攻击在语义上足够明显，能从文本中识别；二是能够显式建模 Agent 之间的交互关系，并用图结构追踪恶意行为的传播。

但真实场景中的攻击可以经过改写，表面上像正常协作内容；而 Agent 的运行也可能是异步的，难以准确还原统一的传播顺序。论文因此关注一种不必依赖显式交互图的检测方式。

2. AcMAS 的主要做法

AcMAS 分析 Agent 的**内部激活状态**，也就是模型处理信息时内部产生的表示，而不只看最终输出的文本。它利用这些状态中的信号判断 Agent 是否表现出恶意行为。

论文还提出将这些信号用于辅助恢复受影响 Agent 的功能。作者将这一点与直接隔离可疑 Agent 的做法作对比：隔离可能打断协作，而恢复思路希望在防御恶意行为的同时保留系统可用性。这里应谨慎表述为“提供恢复线索或支持恢复”，不能理解为所有受感染 Agent 都能被可靠修复。

3. 实验怎么验证

论文将 AcMAS 与基于交互图的方法作比较，重点测试隐蔽攻击，并考察同步与异步运行情形。作者报告，在同步设置下，AcMAS 的 F1 为 **0.94**，图方法基线为 **0.72**；在异步设置下，分别为 **0.93** 和 **0.38**。论文还报告了在不同开源模型、攻击强度和多 Agent 系统规模下的泛化实验。

三、论文总结

论文的主要贡献可以概括为三点：第一，把多 Agent 安全检测的观察对象从文本和显式通信图扩展到模型内部激活状态；第二，针对异步执行和语义隐蔽攻击提出一种不依赖显式交互图的检测框架；第三，尝试让检测结果支持受影响 Agent 的功能恢复，而不只采取隔离处置。论文报告的实验结果显示，这一方法在其测试的同步、异步设置中都优于所比较的图方法基线。

它也有需要讨论的局限。首先，方法依赖访问模型内部激活信息，因此对闭源模型或无法取得内部状态的部署环境，适用性可能受限。其次，论文摘要提供的是特定基准与攻击设置下的结果；实际系统中的攻击类型、模型变化和协作协议更复杂，数字不能直接外推。最后，“恢复 Agent”涉及恢复质量和残余风险，汇报中应进一步核对正文实验后再判断其效果，不能仅凭摘要将它说成已解决的能力。

四、问题

1. MAS是什么：MAS = Multi-Agent Systems，即多智能体系统。一个 Agent 负责规划，一个负责检索，一个负责执行，彼此交换信息、共同完成任务。每个 Agent 背后都有用于生成回答或决策的语言模型。
2. Agent 模型内部的激活状态是什么：Agent 所用的语言模型在处理输入时，各层计算产生的内部数值向量。例如，一个 Agent 收到协作消息后，语言模型会经过多层计算再生成回答。各层中间产生的向量就是激活信息。
3. AcMAS 是作者提出的、基于激活信息的多智能体恶意行为检测框架名称。它的基本思路是，采集各 Agent 的模型内部激活信息 → 分析恶意行为信号 → 判断哪些 Agent 出现异常 → 为后续恢复提供信号。它希望解决的是，恶意消息在文字上可能很隐蔽，而且 Agent 异步运行时，显式通信图难以准确建模；作者因此转向各 Agent 本地模型的激活信息进行检测。
4. 落脚点到底是检测，还是防御？**主要落脚点是检测，检测属于防御的一部分。**